



ClassicLiteratureRAG

*Ответы по тексту классики — с цитатой и адресом главы.
Без выдумок.*

Демо: huggingface.co/spaces/ArtemResearch/ClassicLiteratureRAG

Код: github.com/LiterallyBruh/classic-rag

Junior ML Contest · AI Talent Hub, ИТМО · 2026

Проблема: LLM уверенно выдумывают классику

27 / 29

ответов GigaChat содержат
выдуманную «цитату»

2 / 15

верных адресов главы — там,
где адрес спрашивался



ответ нечем проверить, а
цена ошибки — оценка на
экзамене

Кому это важно:



школьники — сочинения, ЕГЭ



студенты-гуманитарии



преподаватели литературы

Замер на 29 вопросах нашего eval-набора — методика на слайде 7

Решение: ответ только по первоисточнику

”

— Кому принадлежит «мир спасёт красота»?

Слова передают со слов князя Мышкина: «правда, князь, что вы раз говорили, что мир спасёт „красота“?»

(Идиот, часть 3, глава 5)

Если ответа в тексте нет:

«В предоставленных фрагментах текста ответа нет»

честный отказ вместо правдоподобного вымысла

Почему не хватает существующего:

LLM-чаты	ответ непроверяем — см. слайд 2
Краткие содержания (Брифли)	нет цитат и адресов для сочинения
Поиск по тексту (Ctrl+F)	не понимает перефразировок и «Родю»

Данные: воспроизводимый корпус и проверенный eval



Корпус — общественное достояние

«Преступление и наказание», «Идиот», «Бесы», «Фауст» строго в переводе Холодковского (современные переводы охраняются). ~650 тыс. слов.

скачивание
(az.lib.ru)



очистка HTML
(state-machine)



разметка: часть,
глава, сцена, реплика



чанкинг —
3 стратегии

данные не в git — всё строится одним скриптом (bootstrap.py)



EDA → решения

длины абзацев → параметры чанкинга;
частоты имён → словарь 87 алиасов («Родя»
→ «Раскольников»)



Eval: 120 вопросов

по 30 на книгу (факты / цитаты /
интерпретация); валидность всех 120
проверена программно против корпуса

Архитектура: гибридный retrieval + генерация с цитированием



Решения приняты по экспериментам (14 записей в docs/decisions.md):

- индекс — файлы, без векторной БД: на 10^4 чанков nupru-перебор быстрее инфраструктуры
- RRF вместо взвешенной суммы — не требует калибровки шкал BM25 и косинуса
- структурные вопросы («чем заканчивается?») — мимо similarity-поиска: срез конца книги; класс найден на живом демо и закрыт итерацией
- LLM за адаптером: GigaChat (кэш OAuth) или любой OpenAI-совместимый эндпоинт

Эксперименты: чанкинг и реранкер на 120 вопросах

Конфигурация	span@1	span@5	MRR
окна, гибрид BM25+e5	0.23	0.42	0.32
окна, гибрид + reranker	0.39	0.57	0.47
абзацы, гибрид + reranker	0.31	0.45	0.37
главы, гибрид + reranker	0.33	0.59	0.43

+70 %

к точности топ-1 даёт реранкер
— самый выгодный компонент

- span recall — в топ-k есть чанк с золотой подстрокой ответа
- «главы» выигрывают только размером чанка: в контекст LLM такой чанк не влезает — для продукта непригодно
- **выбор: окна ~180 слов, не пересекающие границ глав**

Импакт: тот же GigaChat — с текстом романа и без

27 → 1

ответов с цитатой, которой нет в тексте
— из 29

2 → 12

верных адресов главы — из 15
вопросов с адресом в эталоне

0 → 9

честных отказов вместо вымысла — из
29

Из чего состоят те же 29 ответов:

GigaChat API

без доступа к тексту

27 ответов с «цитатой» — все цитаты выдуманы

2 ответа вовсе без цитаты

ClassicLiteratureRAG

тот же GigaChat + retrieval

8 с дословной цитатой

1 сжатая цитата

9 ответов без цитаты

9 честных отказов

2 заблокировала модерация Сбера

10 ≈ 11

верных по сути · из 29

Модель не стала «умнее» — но у baseline даже верные ответы подкреплены выдуманной цитатой, их не отличить от неверных. **Вклад RAG: верное можно проверить, вместо вымысла — отказ.**

Тот же вопрос — два ответа (из прогона, без правок)

«Кто говорит „Если нет бога, то я бог“?» — эталон: Кириллов, часть 3, глава 6

GigaChat API без доступа к тексту

«Эти слова произносит Ставрогин. Цитата: „— Если нет Бога, то я Бог! — вдруг крикнул он громко и с восторгом“. Часть I, глава 1.»

ClassicLiteratureRAG

«„Если нет бога, то я бог“ говорит Кириллов (Бесы, часть 3, глава 6 „Многотрудная ночь“, раздел 2)»



герой не тот · такой цитаты в романе нет · «часть I, глава 1»
— мимо



герой верен · цитата дословна · адрес совпал с золотой
разметкой

Ответы взяты из eval/baseline_raw.json как есть — каждый можно перепроверить в репозитории.

Веб-версия GigaChat — не «без RAG»: в ней встроен поиск по интернету; baseline — чистая модель через API.

Инженерия, продукт и AI-инструменты



Инженерия

- 35 юнит-тестов без сети, ruff, CI (GitHub Actions)
- Docker с CPU-torch; деплой на HF Spaces одним скриптом
- готовый индекс через git-lfs — старт за секунды



AI-инструменты

- разработка в паре с Claude Code
- каждый шаг — в docs/ai_usage_log.md с проверкой результата
- 14 дизайн-решений с аргументацией в docs/decisions.md



Продукт живёт

- MVP задеплоен, доступен жюри
- фидбек «помог / не помог» + комментарий → приватный HF-датасет



Итерация по фидбеку

- живой отказ демо → класс структурных вопросов
- диагностика → фикс → метрики до/после (D-011)

Проверяемые ответы по классике — уже работают

27 → 1

выдуманных цитат из 29
(GigaChat: без текста → с ним)

+70 %

к точности retrieval
от реранкера

650 тыс.

слов в корпусе,
готовом к расширению

Дальше: атрибуция реплик персонажам · faithfulness-метрика LLM-судьёй · расширение корпуса

Демо: huggingface.co/spaces/ArtemResearch/ClassicLiteratureRAG

Спасибо! Вопросы?